

Proyecto Final: Pipeline Básico de Procesamiento de Datos

Cargar, limpiar, transformar, analizar y guardar un dataset real · Python

- Numpy
- Pandas
- Valores nulos
- Feature engineering
- Groupby
- Guardar resultados

SISTEMA	Python 3 · VS Code
DATASET	Hollywood Movies (970 películas, con nulos reales)
ARCHIVO	proyecto_pipeline.py
TIEMPO ESTIMADO	2.5 – 3 horas, individual
REQUISITO PREVIO	Los 4 temas del Mes 2 completos (Python Aplicado, Estructuras de Datos, Numpy y Pandas, Manipulación de Datasets)
FORMATO	Sin código de solución. Estructura por etapas, con un checkpoint de autoevaluación al final de cada una
OBJETIVO	Construir, de principio a fin, un pipeline que convierta un dataset real y desordenado en uno limpio, listo para usarse
ENTREGA	Archivo proyecto_pipeline.py corriendo sin errores, más el archivo hollywood_limpio.csv generado al final

Qué es distinto en este proyecto

Las prácticas del mes te dieron soluciones para autoevaluarte. Este proyecto no. Aquí encuentras 6 etapas, con los requisitos de cada una y pistas sobre errores conocidos, pero sin código de referencia. Ya construiste, por separado, cada una de las piezas que necesitas (cargar, limpiar, transformar, analizar, guardar) a lo largo de las 4 clases del mes. Este proyecto es unir las tú mismo, en un dataset que nunca has visto.

CÓMO FUNCIONA CADA ETAPA

Requisitos: qué tiene que lograr esa etapa, sin decirte la línea de código exacta.

Checkpoint: un resultado parcial (una forma, un conteo) para que confirmes que vas bien antes de pasar a la siguiente etapa. No es la solución completa, es solo un punto de referencia.

Pista, cuando aplica: un recordatorio de qué concepto del mes corresponde a esa etapa.

LAS 6 ETAPAS DEL PIPELINE

1. Cargar y diagnosticar · 2. Limpiar · 3. Crear columnas nuevas · 4. Tipos de datos y ordenar · 5. Agrupar y analizar · 6. Guardar el resultado

NOTA SOBRE EL ARCHIVO

Todo el código va en un solo archivo: `proyecto_pipeline.py`. Ve completando las etapas en orden, cada una depende de que la anterior haya quedado bien hecha.

Sobre este dataset

970 películas de Hollywood, con su estudio, género, calificaciones de crítica y audiencia, y sus cifras de taquilla. Nunca lo usaron en clase, así que va a tener sus propias sorpresas de datos que no vieron con el Titanic.

COLUMNA	QUÉ CONTIENE
Movie	Título de la película
LeadStudio	Estudio productor principal
Genre	Género de la película
RottenTomatoes	Calificación de la crítica (0 a 100)
AudienceScore	Calificación de la audiencia (0 a 100)
WorldGross	Recaudación mundial, en millones de dólares
Budget	Presupuesto de producción, en millones de dólares
Year	Año de estreno

DESCARGAR EL DATASET

```
# Windows (PowerShell)
Invoke-WebRequest -Uri "https://raw.githubusercontent.com/reisanar/datasets/master/HollywoodMovies.csv" -OutFile hollywood.csv

# Windows, si el comando de arriba no funciona (PowerShell o CMD)
curl.exe -O https://raw.githubusercontent.com/reisanar/datasets/master/HollywoodMovies.csv

# Mac / Linux (Terminal)
curl -O https://raw.githubusercontent.com/reisanar/datasets/master/HollywoodMovies.csv
```

POR QUÉ HAY 2 OPCIONES PARA WINDOWS

En PowerShell, escribir curl a secas en realidad ejecuta Invoke-WebRequest por dentro (es un alias), no el programa curl real. Si Invoke-WebRequest falla por algún motivo, curl.exe (escrito así, completo) sí llama al programa real, que Windows 10 y versiones más recientes ya traen instalado, y suele funcionar como respaldo. curl.exe funciona igual en PowerShell y en CMD.

IMPORTANTE: EL ARCHIVO ORIGINAL TIENE MÁS DE 8 COLUMNAS

El CSV que descargas trae 16 columnas. Para este proyecto, la Etapa 1 te pide quedarte solo con las 8 de la tabla de arriba, y descartar el resto. Trabajar con menos columnas, pero bien entendidas, es mejor que trabajar con todas sin saber qué significan.

Cargar y diagnosticar

REQUISITOS

Carga el archivo descargado. Quédate solo con estas 8 columnas: Movie, LeadStudio, Genre, RottenTomatoes, AudienceScore, WorldGross, Budget, Year. Diagnostica: la forma del dataset (filas y columnas), y cuántos valores nulos tiene cada columna.

PISTA

Para quedarte solo con ciertas columnas, usa el mismo patrón de selección con doble corchete que ya viste en la Clase 6. No necesitas eliminar las columnas que no quieres una por una.

CHECKPOINT: CONFIRMA ESTO ANTES DE SEGUIR

Después de seleccionar las 8 columnas, tu dataset debería tener exactamente **970 filas y 8 columnas**. Al diagnosticar los nulos, deberías ver que Genre tiene la mayor cantidad de valores vacíos de las 8, y que Year no tiene ningún nulo.

PREGUNTA DE RAZONAMIENTO

¿Por qué diagnosticar el dataset completo (forma, nulos) antes de limpiar nada, en vez de empezar a limpiar directamente desde la primera columna que veas?

Escribe tu respuesta en tu README.md, no aquí.

Limpiar

No todas las columnas necesitan la misma solución. Decide caso por caso, como ya practicaron con el Titanic.

REQUISITOS

Para Genre y LeadStudio (columnas de texto): rellena los valores nulos con una categoría de reemplazo razonable, en vez de eliminar esas filas.

Para RottenTomatoes y AudienceScore (columnas numéricas): rellena los nulos con una medida que ya usaron en el Tema 4, que no se distorsione tanto con valores extremos.

Para WorldGross y Budget: son pocas filas afectadas. Elimínalas en vez de rellenarlas, ya que vas a necesitar estos 2 números exactos más adelante.

POR QUÉ NO TRATAR TODAS LAS COLUMNAS IGUAL

Rellenar Genre con un número no tendría sentido (es texto), y eliminar todas las filas con algún nulo de las 8 columnas dejaría el dataset demasiado chico, porque Genre por sí solo tiene casi 3 de cada 10 filas vacías. **La decisión correcta depende del tipo de columna y de qué tan grave es el vacío**, exactamente como ya vieron con el Titanic.

CHECKPOINT PARCIAL: COLUMNAS DE TEXTO

Después de rellenar Genre y LeadStudio, ninguna de las dos debería tener nulos todavía, pero RottenTomatoes, AudienceScore, WorldGross y Budget sí deberían seguir teniendo los suyos en este punto intermedio.

PREGUNTA DE RAZONAMIENTO

¿Qué pasaría si rellenaras Budget con 0 en vez de eliminar esas filas? ¿Cómo afectaría eso a la columna Ganancia que vas a crear en la próxima etapa?

Escribe tu respuesta en tu README.md, no aquí.

CHECKPOINT: CONFIRMA ESTO ANTES DE SEGUIR

Después de limpiar las 6 columnas, tu dataset debería tener **0 valores nulos en total**, y quedar con **897 filas** (algunas se perdieron al eliminar las de WorldGross/Budget vacíos).



Crear columnas nuevas

REQUISITOS

Crea una columna `Ganancia`, que sea el resultado de restarle el presupuesto (`Budget`) a la recaudación mundial (`WorldGross`).

Crea una columna `Exitosa`, que sea `True` si la calificación de la crítica (`RottenTomatoes`) es de 60 o más, y `False` en cualquier otro caso.

PISTA

`Ganancia` se construye con una operación entre columnas, igual que `FamiliaTotal` en el Tema 4. `Exitosa` se construye con una comparación entre una columna y un número, igual que `EsMenorDeEdad`.


CHECKPOINT: CONFIRMA ESTO ANTES DE SEGUIR

Al contar los valores de `Exitosa` con `.value_counts()`, deberías obtener más películas con `False` que con `True` (519 contra 378). Si te sale al revés, revisa si escribiste la comparación en el sentido correcto.

PREGUNTA DE RAZONAMIENTO

`Ganancia` se calcula restando (`WorldGross - Budget`). ¿Qué representaría, en cambio, una columna que dividiera `WorldGross` entre `Budget`? ¿En qué caso preferirías esa versión en vez de la resta?

Escribe tu respuesta en tu `README.md`, no aquí.



Tipos de datos y ordenar

REQUISITOS

Confirma con `.dtypes` que `Exitosa` quedó guardada como un tipo booleano, no como texto ni número.
Ordena el dataset por `Ganancia`, de mayor a menor, e imprime el nombre y la ganancia de las 3 películas más rentables.

PISTA

Si construiste `Exitosa` con una comparación (`>=`), Pandas ya la guarda como booleano automáticamente, sin que tengas que convertirla tú. Este paso es solo para confirmarlo, no necesariamente para cambiar nada.


CHECKPOINT: CONFIRMA ESTO ANTES DE SEGUIR

La película más rentable de todo el dataset debería tener una ganancia de más de 2,500 millones de dólares. Si tu resultado es muy distinto, revisa si ordenaste de mayor a menor, o al revés.

PREGUNTA DE RAZONAMIENTO

¿Qué habría pasado si hubieras intentado ordenar por `Ganancia` antes de limpiar los nulos de `WorldGross` y `Budget` en la Etapa 2? ¿Por qué el orden en que se hacen las etapas importa aquí?

Escribe tu respuesta en tu `README.md`, no aquí.



Agrupar y analizar

REQUISITOS

Agrupar el dataset por `Genre`, y calcular el promedio de `RottenTomatoes` de cada género, redondeado a 1 decimal.
Agrupar el dataset por `LeadStudio`, y calcular el promedio de `Ganancia` de cada estudio, redondeado a 1 decimal.

PISTA

Recuerda que `.groupby()` por sí sola no muestra nada útil, necesita una función de agregación encadenada después, igual que en el Tema 4.


PREGUNTA DE RAZONAMIENTO

De los géneros con más películas en el dataset (Comedia, Acción, Drama), ¿cuál tiene el promedio de calificación de crítica más alto? ¿Te sorprende, o era lo que esperabas?

Escribe tu respuesta en tu `README.md`, no aquí.

CHECKPOINT: CONFIRMA ESTO ANTES DE SEGUIR

El género con la calificación promedio más alta de todo el dataset no debería ser ninguno de los 3 géneros más comunes (Comedia, Acción, Drama), sino uno con muchas menos películas.



Guardar el resultado

REQUISITOS

Guarda el dataset ya limpio y con las columnas nuevas en un archivo llamado `hollywood_limpio.csv`, sin la columna extra de índice que Pandas agregaría por defecto.

PISTA

Hay un argumento específico de `.to_csv()` que evita esa columna extra. Ya lo usaron en el Tema 4.

CHECKPOINT FINAL

Abre el archivo `hollywood_limpio.csv` que acabas de generar (o cárgalo de nuevo con `pd.read_csv()` en una línea aparte) y confirma: 897 filas, 10 columnas (las 8 originales más `Ganancia` y `Exitosa`), y 0 valores nulos.

PREGUNTA DE RAZONAMIENTO

¿Por qué guardar el resultado en un archivo nuevo (`hollywood_limpio.csv`), en vez de sobrescribir el archivo original `hollywood.csv` que descargaste?

Escribe tu respuesta en tu README.md, no aquí.

Escenarios: ¿qué harías si...?

Estas 3 preguntas no tienen que ver con el dataset de películas específicamente. Buscan confirmar que entendiste los **principios** detrás de cada etapa, no solo los pasos exactos que seguiste con Hollywood Movies. Respóndelas en tu README.md, con 2 o 3 frases cada una, sin necesidad de escribir código.

ESCENARIO 1

Si el dataset tuviera una columna de fechas completas (día, mes y año) en vez de solo el año, ¿qué tendrías que verificar antes de poder ordenar el dataset cronológicamente por esa columna?

ESCENARIO 2

Si quisieras aplicar este mismo pipeline a un dataset completamente distinto (por ejemplo, canciones con su artista, género y número de reproducciones), ¿qué partes de tu código cambiarían, y cuáles seguirían exactamente igual?

ESCENARIO 3

Si una columna nueva tuviera 95% de sus valores nulos (mucho peor que Gen re, que tenía cerca del 29%), ¿seguirías rellenándola de la misma forma? ¿Qué harías distinto, y por qué?

POR QUÉ ESTO ES PARTE DEL PROYECTO, NO UN EXTRA

Cualquiera puede seguir instrucciones y llegar al mismo resultado con el mismo dataset. **Responder estos 3 escenarios es lo que confirma que podrías repetir este proceso con un dataset que nunca has visto**, sin que nadie te dé de nuevo las 6 etapas paso a paso.

Entregables y autoevaluación

QUÉ DEBES ENTREGAR

1. Tu archivo `proyecto_pipeline.py`, corriendo sin errores, de principio a fin.
2. El archivo `hollywood_limpio.csv` que tu propio código genera al final.
3. Un archivo `README.md` con tus respuestas escritas (ver estructura abajo).

ESTRUCTURA SUGERIDA DEL README.MD

1. **Descripción:** 2-3 líneas sobre qué hace tu pipeline.
2. **Preguntas de razonamiento:** tus 6 respuestas, una por etapa.
3. **Escenarios de transferencia:** tus 3 respuestas de la página anterior.

- ☐ Mi dataset quedó con exactamente 970 filas después de seleccionar las 8 columnas
- ☐ Traté cada columna con nulos de forma distinta, según si era texto, número, o pocas filas afectadas
- ☐ Mis columnas nuevas (Ganancia, Exitosa) coinciden con los checkpoints correspondientes
- ☐ Mi archivo `hollywood_limpio.csv` se genera correctamente, sin columna de índice extra
- ☐ Respondí las 6 preguntas de razonamiento y los 3 escenarios en mi `README.md`
- ☐ Mi archivo `proyecto_pipeline.py` corre de principio a fin sin ningún error

SI TE TRABASTE EN ALGUNA ETAPA

Vuelve al tema correspondiente del mes: Tema 3 para cargar y explorar, Tema 4 para limpiar, transformar, agrupar y guardar. Todo lo que necesitas para este proyecto ya lo practicaste antes, en un dataset distinto.